

Pesquisa profunda sobre monitoramento de vagas e candidaturas no Brasil

Resumo executivo

Para um produto sério de monitoramento de vagas no Brasil, a conclusão mais importante é esta: **as superfícies oficiais realmente aproveitáveis hoje ficam concentradas em APIs e webhooks de ecossistemas B2B/ATS** — como Gupy, Vagas.com Empresas, Catho API Pública, Indeed Partner Docs, PandaPé/Infojobs, Meta Pages/WhatsApp Business e Telegram Bot API — enquanto **LinkedIn, Indeed para candidatos, Glassdoor e os grupos sociais fechados** exigem muito mais cautela jurídica e operacional para qualquer automação. Em outras palavras: o melhor desenho não é “raspar tudo”, e sim **combinar alertas nativos, e-mail parsing, APIs/webhooks oficiais e scraping seletivo, proporcional e defensável**. ¹

Também há uma fronteira clara para candidatura automática. O LinkedIn veda coleta automatizada sem autorização expressa e mantém termos específicos de crawling; o Indeed proíbe bots, scripts e automação de candidatura fora das ferramentas oficiais. O Glassdoor, por sua vez, hoje encaminha candidatura pelos serviços do Indeed e deixou de apoiar novas parcerias de API. Por isso, a política mais segura para um produto candidato-side é: **prefill + confirmação humana por padrão; submissão silenciosa só em integrações autorizadas pelo empregador/ATS**. ²

Na prática brasileira, vale pensar em quatro famílias de fontes. A primeira é de **job boards generalistas estruturados**: Vagas.com.br, Infojobs, Catho, Indeed, Glassdoor, Empregos.com.br. A segunda é de **ATS/carreiras corporativas e marketplaces com camada estruturada**: Gupy, Tramos.co, GeekHunter, Revelo. A terceira é de **comunidades sociais públicas**: canais/grupos públicos no Telegram, Páginas/contas profissionais no Facebook e Instagram. A quarta é de **canais sociais com automação fraca ou restrita**, principalmente WhatsApp, onde existe API oficial robusta para **mensageria de negócio** e webhooks, mas não um caminho oficial equivalente para “ler arbitrariamente grupos de vagas” como fonte pública de monitoramento. ³

Do ponto de vista de produto, a melhor arquitetura para começar no Brasil é um **hub de oportunidades** que normalize dados de múltiplas fontes, gere um **feed interno próprio** (inclusive RSS de saída seu, já que RSS nativo oficial é raro nas plataformas revisadas), aplique **deduplicação por vaga/carreira**, ranqueie aderência do candidato, mantenha um **CRM de candidaturas** e una isso a um **inbox operacional** para alertas, entrevistas e follow-ups. Como o sistema vai lidar com currículo, pretensão salarial, histórico de candidaturas e em alguns casos dados sensíveis ligados a inclusão/PCD, ele deve nascer com controles de LGPD, minimização, retenção, trilha de auditoria e preferências de visibilidade desde o MVP. ⁴

Mapa das plataformas

Antes do mapa, duas notas metodológicas. A primeira: quando eu marco **“RSS público não localizado”** ou **“API pública de candidato não localizada”**, isso significa que **não encontrei documentação oficial pública nas fontes revisadas até 26/05/2026**; não é prova absoluta de inexistência. A segunda: a

coluna “**dificuldade de coleta**” é **minha avaliação prática**, baseada em autenticação, renderização, políticas anti-automação, bloqueios e clareza dos termos. ⁵

Job boards, agregadores, ATSS e marketplaces

Plataforma	Cobertura e público	Recursos principais	API/RSS e autenticação	Dificuldade de coleta	Restrições legais e operacionais
LinkedIn	Brasil + global; público geral/profissional.	Busca, alertas diários/semanais, alertas por empresa, candidatura rápida em parte das vagas, metadados de nível de experiência/tipo de emprego/função/setor.	Conta obrigatória para alertas; não localizei API pública oficial de busca de vagas para candidatos ; RSS público não localizado.	Alta. Forte fricção de login, limites comportamentais e sensibilidade anti-bot.	LinkedIn proíbe crawling/extração automatizada sem permissão expressa; termos de jobs também vedam automação/scraping sem autorização. ⁶
Vagas.com.br	Brasil; generalista e forte em “trabalhe conosco”.	Busca com filtros, alertas/buscas salvas no app e por e-mail, páginas de empresas, vagas confidenciais que podem ocultar empresa/localização.	Área do candidato exige conta; Vagas Empresas expõe APIs de feed de vagas, publicação e exportação de candidatos; RSS público não localizado.	Média/alta. Parte do conteúdo público é acessível, mas há páginas com 403 e fricção por login.	Termos do domínio principal do candidato não ficaram acessíveis ao crawler nesta pesquisa; para integrações oficiais, a Vagas expõe APIs B2B e documentação corporativa. Em compliance, trate como canal com políticas próprias e sem licença implícita para scraping amplo. ⁷

Plataforma	Cobertura e público	Recursos principais	API/RSS e autenticação	Dificuldade de coleta	Restrições legais e operacionais
InfoJobs	Brasil; generalista.	Busca com filtros e mapa, alertas configuráveis, mensagens/entrevistas no “Área do Candidato”, comparativo de aderência, currículos e cartas modelo.	Conta para alertas/candidaturas; API corporativa no PandaPé ATS ; RSS público não localizado.	Média. Há bastante conteúdo indexado e páginas públicas; automação ainda deve respeitar termos e privacidade.	O aviso legal detalha visibilidade de currículo, alertas, conteúdo de terceiros e uso do portal; para ATS, o PandaPé oferece integração via API. ⁸
Catho	Brasil; generalista com alto volume.	Busca por estado/cargo, aviso de vagas, currículos, salários, vagas parceiras.	Conta para candidato; API pública para integradores/empresas ; RSS público não localizado.	Média para páginas públicas, alta para fluxos autenticados.	A Catho publica termos de API pública com proibição explícita de scraping/data mining/replicação de base e limite diário de requisições por usuário final; o aviso de vagas é diário. ⁹
Indeed	Brasil + global; agregador/job board generalista.	Alertas, recomendações de vagas, perfil pesquisável, candidatura via Indeed, mensagens e gestão de candidatos para empresas.	Conta para alertas; docs oficiais de parceiro com Job Sync, Candidate Sync, Indeed Apply e integrações; RSS público não localizado.	Alta fora de integrações oficiais.	Termos vedam bots/scripts para automatizar candidatura fora das ferramentas oficiais; o portal de parceiros controla APIs, chaves e monitoramento de uso. ¹⁰

Plataforma	Cobertura e público	Recursos principais	API/RSS e autenticação	Dificuldade de coleta	Restrições legais e operacionais
Glassdoor	Brasil + global; busca de vagas + salários + reviews + entrevista.	Vagas, salários, avaliações, alertas, candidatura rápida em parte do acervo.	Conta obrigatória para acesso pleno; candidaturas passam pelos serviços do Indeed ; help oficial informa que não há mais suporte a parcerias de API . RSS público não localizado.	Alta . Conteúdo altamente acoplado a login, recomendações e ecossistema Indeed.	Termos do Glassdoor remetem a termos e privacidade do Indeed para candidatura; como fonte, é melhor tratá-lo como enriquecimento de contexto, não como canal principal de automação. ¹¹
Gupy	Brasil; ATS/ carreiras corporativas com portal agregado.	Busca pública no portal, career pages, fases do processo, benefícios/salário em muitas vagas, candidatura via WhatsApp em oferta comercial.	APIs públicas e webhooks oficiais ; autenticação por token; acesso condicionado a plano/ permissões de admin em alguns cenários; RSS público não localizado.	Baixa/média via integração oficial; alta se tentar simular candidato autenticado sem parceria.	Excelente superfície para integrações autorizadas; docs oficiais tratam autenticação, webhooks e extração para BI. Para produto candidato-side sem parceria, prefira coleta pública + abertura do formulário oficial. ¹²

Plataforma	Cobertura e público	Recursos principais	API/RSS e autenticação	Dificuldade de coleta	Restrições legais e operacionais
Empregos.com.br	Brasil; generalista.	Cadastro grátis, candidatura com 1 clique, alertas por e-mail, filtros por modalidade, compartilhamento social da vaga.	Conta para candidatura/alerta; não localizei API pública oficial para candidatos ; RSS público não localizado.	Média. Há páginas públicas ricas em metadados.	Os termos públicos revisados são voltados a serviços de recrutamento on-line e enfatizam finalidade de recrutamento e LGPD; bom candidato a coleta pública moderada com cautela. ¹³
Trampos.co	Brasil; nicho forte em comunicação, marketing, criação, gestão e tech.	Oportunidades setoriais, banco de talentos, alertas ligados a redes sociais, ATS próprio e integrações com Gupy/TOTVS.	Conta recomendada; integrações ATS documentadas para empresas; não localizei API pública de vagas para candidatos ; RSS público não localizado.	Média. Estrutura relativamente amigável, mas com partes voltadas a login/ATS.	Ótimo para nichos digitais. Termos citam alertas de emprego e gestão da busca; integrações são corporativas. ¹⁴
GeekHunter	Brasil com forte viés tech; também exhibe oportunidades em moedas e mercados globais.	Perfil-first, matching inteligente, vagas tech, recrutadores e talentos validados.	Conta para perfil/candidatura; não localizei API pública oficial ; RSS público não localizado.	Média na área pública; alta em fluxos autenticados e matching.	Termos próprios e forte dependência de perfil. Para monitoramento, use páginas públicas de vagas; para candidatura, prefira condução no fluxo da plataforma. ¹⁵

Plataforma	Cobertura e público	Recursos principais	API/RSS e autenticação	Dificuldade de coleta	Restrições legais e operacionais
Revelo	Brasil, América Latina e Estados Unidos; nicho tech e remoto.	Perfil único, matching por preferências/habilidades/salário, vagas remotas, carreiras em dólar, abordagem company-first.	Conta para participação plena; não localizei API pública oficial ; RSS público não localizado.	Média em páginas públicas de carreiras; alta no fluxo autenticado de matching.	Mais marketplace de talentos do que job board clássico; excelente para monitoramento de nicho tech, mas a automação de candidatura deve respeitar o fluxo da Revelo.

16

Redes e comunidades sociais usadas para vagas

Plataforma/canal	Cobertura e público	Recursos principais	API/RSS e autenticação	Dificuldade de coleta	Restrições legais e operacionais
Telegram	Global, mas muito útil em canais/grupos públicos brasileiros de nicho.	Canais públicos, grupos, bots, links de convite, notificações em tempo real.	Bot API , Telegram API e TDLib oficiais; bot token ou conta cliente; sem RSS nativo.	Baixa/média em canais públicos autorizados; alta em grupos privados ou sem permissão.	Bot/API só devem operar com acesso legítimo; grupos/chats privados permanecem privados entre participantes; há limites oficiais e termos de API.

17

Plataforma/ canal	Cobertura e público	Recursos principais	API/RSS e autenticação	Dificuldade de coleta	Restrições legais e operacionais
WhatsApp	Global; muito usado em grupos/comunidades informais de vagas no Brasil.	Grupos, comunidades, canais, listas de transmissão, mensageria móvel onipresente.	Cloud API e webhooks oficiais existem para WhatsApp Business Platform , não para “ler arbitrariamente grupos/canais públicos” como monitor de vagas; sem RSS nativo.	Alta para monitoramento automatizado de grupos; baixa/média apenas para fluxos de negócio da conta autorizada.	Excelente para alertas de saída e relacionamento com o usuário final; fraco para ingestão oficial de grupos de terceiros . Requer verificação/configuração Meta para integração formal. ¹⁸
Meta social: Instagram + Facebook Pages/Groups	Global; muito usado em employer branding, páginas de vagas e comunidades abertas.	Páginas, posts, comentários, contas profissionais, webhooks em ativos próprios/autorizados.	Facebook Pages API , Graph API, Instagram Platform e webhooks para páginas/contas profissionais autorizadas; sem RSS nativo.	Média para ativos próprios/autorizados; alta para monitorar arbitrariamente páginas/perfis/grupos de terceiros.	As versões oficiais funcionam muito bem para seus próprios ativos ou ativos com permissão; para páginas/perfis de terceiros, o caminho correto é autorização, Page Public Content Access quando aplicável, ou monitoramento manual/parceiros aprovados. ¹⁹

Comparativo operacional de dados e monitoramento

Na tabela abaixo, ✓ significa “tipicamente exposto”, ● significa “depende muito da vaga, do anunciante ou do tipo de página”, e — significa “raro ou não documentado como estrutura estável”. Como a maioria das plataformas **não publica SLA de atualização para candidatos**, a coluna final traz a **minha recomendação de ingestão** para um sistema de monitoramento. ²⁰

Sites e ATSS

Plataforma	Título	Empresa	Local	Salário	Senioridade	Remoto/ Híbrido	Requisitos	Benefícios	Lin
LinkedIn	✓	✓	✓	●	✓	✓	✓	●	v
Vagas.com.br	✓	●	●	●	●	●	✓	●	v
InfoJobs	✓	✓	✓	●	●	✓	✓	●	v
Catho	✓	✓	✓	●	●	✓	✓	●	v
Indeed	✓	✓	✓	●	●	●	✓	●	v
Glassdoor	✓	✓	✓	●	●	●	✓	●	v

Plataforma	Título	Empresa	Local	Salário	Senioridade	Remoto/ Híbrido	Requisitos	Benefícios	Link
Gupy	✓	✓	✓	●/✓	✓	✓	✓	✓	✓
Empregos.com.br	✓	✓	✓	●	—	✓	✓	●	✓
Trampos.co	✓	✓	✓	●	●	✓	✓	●	✓
GeekHunter	✓	✓	✓	✓/●	✓	✓	✓	●	✓
Revelo	✓	●	●	✓/●	✓	✓	●	✓/●	✓

Redes e comunidades

Plataforma	Título	Empresa	Local	Salário	Senioridade	Remoto/ Híbrido	Requisitos	Benefícios	Link
Telegram público	●	●	●	●	●	●	●	—	✓

Plataforma	Título	Empresa	Local	Salário	Senioridade	Remoto/ Híbrido	Requisitos	Benefícios	Link
WhatsApp grupos/ comunidades/ canais	●	●	●	●	●	●	●	—	✓
Instagram/ Facebook pages	●	✓	●	●	●	●	●	—	✓


Algumas leituras práticas saem direto dessa matriz. **Gupy, Vagas Empresas, Catho API, Indeed Partner APIs, PandaPé e Meta/Telegram** são os melhores alvos para **integração oficial**. **LinkedIn, Indeed candidato e Glassdoor** são ótimos para descoberta e enriquecimento, mas maus alvos para automação agressiva. **WhatsApp** deve ser tratado principalmente como **destino de alertas/conversas do usuário**, não como origem automatizada de dados de terceiros. ³⁴

Arquiteturas ponta a ponta

As arquiteturas abaixo partem de um princípio simples: **usar primeiro o que é oficial e contratualmente sustentável** e só depois adicionar raspagem seletiva onde o risco e o ganho justificam. Esse princípio é especialmente importante porque há, ao mesmo tempo, APIs/webhooks bem documentados em Gupy, Indeed, Vagas, Catho, PandaPé, Meta e Telegram, e proibições claras de automação não autorizada em LinkedIn e Indeed. ³⁵

Arquitetura A — Compliance-first com alertas + inbox operacional

Use alertas nativos das plataformas, e-mails transacionais, webhooks oficiais e poucas integrações diretas. A entrada principal é o **inbox** do candidato/usuário: e-mails do LinkedIn, Indeed, Catho, Vagas, InfoJobs, Glassdoor/Gupy, mais webhooks de fontes oficiais quando houver parceria. Esse modelo minimiza risco jurídico e entrega valor muito cedo.



Stack sugerida: Python + FastAPI; workers Celery/RQ; PostgreSQL; Redis; armazenamento de anexos em S3/compatível; Meilisearch ou OpenSearch; painel web em Next.js; autenticação por Keycloak/Auth.js.

Complexidade: baixa a média.


Prós: go-live rápido, risco legal baixo, excelente para MVP.

Contras: frescor depende do e-mail em algumas fontes; cobertura menor em plataformas comunitárias.

Privacidade/compliance: forte aderência à LGPD se você separar PII, criptografar anexos/currículos e permitir que o usuário desligue cada conta/fonte. Em automação de candidatura, mantenha **click-to-confirm**. 36

Arquitetura B — Híbrida com APIs oficiais + scraping seletivo

Aqui o backbone continua sendo oficial, mas você adiciona coletores seletivos para páginas públicas de fontes como Empregos.com.br, Tramos.co, algumas páginas públicas de GeekHunter/Revelo e portais/carreiras expostos em Gupy. O scraping fica restrito a HTML público, com backoff, user agent honesto, cache e rastreabilidade.



Stack sugerida: Python/FastAPI + Playwright para fallback controlado; PostgreSQL + pgvector; OpenSearch; fila Redis; orquestração por Temporal ou workers simples; observabilidade com

OpenTelemetry.

Complexidade: média a alta.

Prós: melhor cobertura, melhor frescor, ainda razoavelmente defensável.

Contras: custo operacional maior; exige governança de crawling e revisão por fonte.

Privacidade/compliance: documente por fonte o fundamento de coleta, respeite exclusões/robots quando aplicável, limite retenção de HTML bruto, e mantenha prova de origem por `source_url`, `captured_at`, `source_type`. Para LinkedIn/Indeed/Glassdoor, evite usar esta arquitetura como bypass de termos. ³⁷

Arquitetura C — Assistente de navegador com humano no loop

Essa arquitetura é ideal para um produto “candidate co-pilot”. Em vez de o backend tentar agir como o usuário em massa, a inteligência mora em uma **extensão de navegador** ou agente acoplado à sessão do usuário: lê a vaga aberta, compara com o perfil, preenche campos repetitivos, salva o estado da candidatura e só envia com confirmação explícita.



Stack sugerida: TypeScript + extensão Chrome/Edge/Firefox; backend leve em Node.js ou Python; sync via WebSocket/REST; armazenamento em PostgreSQL.

Complexidade: média.


Prós: ótima UX, reduz fricção, respeita melhor fluxos com autenticação.

Contras: manutenção alta por portal; suscetível a mudanças no front-end; não elimina risco de termos se virar “bot” invisível.

Privacidade/compliance: esse modelo é bom quando o dado processado fica sob controle do usuário e o backend só recebe o necessário. Ainda assim, a regra deve ser **prefill assistido**, não autopilot silencioso. Isso é especialmente importante porque plataformas como Indeed e LinkedIn restringem automação não oficial de candidatura. ³⁸

Arquitetura D — Hub enterprise de carreiras, ATS e comunidades

Este é o desenho para universidade, consultoria de carreira, comunidade tech ou recrutadora que tenha acordos com plataformas e empresas. O foco é **integração oficial por chave/token/webhook**, com data warehouse, BI e operações multicliente.



Stack sugerida: Python ou JVM; API gateway; PostgreSQL + warehouse analítico (ClickHouse/BigQuery equivalente); OpenSearch; fila Kafka/RabbitMQ; Kubernetes; SSO corporativo; BI com Metabase/Power BI.

Complexidade: alta.

Prós: melhor governança, melhor analytics, forte capacidade de scheduling/feedback, multicanal real.

Contras: depende de contratos/parcerias; custo e esforço maiores.

Privacidade/compliance: esta é a arquitetura em que mais importa separar papéis de controlador/operador, base legal, retenção, DSAR, masking e logs de auditoria. Em bases com dados de PCD, saúde, diversidade ou documentos admissionais, trate como fluxo sensível desde o desenho. ³⁹

Minha recomendação prática: **MVP na Arquitetura A**, evolução para **B** quando você dominar a governança por fonte, e adoção de **C** como camada premium de UX. A **D** faz sentido quando existe operação institucional, multiusuário ou acordos com ATs e empregadores. ⁴⁰

Estratégias de UX para aderência parcial

As próprias plataformas já sinalizam, de maneiras diferentes, que existe valor em “aderência” e “matching”: o InfoJobs mostra comparativos de aderência por formação/localização; o Indeed e o LinkedIn usam recomendações e correspondências; a GeekHunter e a Revelo são explicitamente perfil-first. O problema é que essas pistas normalmente são **opacas** para o candidato. Seu produto deve torná-las **explicáveis, acionáveis e calibráveis**. ⁴¹

Estratégias concretas

Estratégia	Como funciona	O que o usuário vê	Regra prática
Skill-gap scoring	Separar requisitos em must-have , should-have e nice-to-have ; aplicar pesos.	“Seu fit é 74/100. Você cobre 4/5 obrigatórios, 3/6 desejáveis.”	Não barrar candidatura se os obrigatórios estiverem em 70–80% e houver forte evidência de transferência.
Transferable-skill matching	Mapear habilidades transferíveis por função/stack/setor.	“Você não tem HubSpot , mas tem CRM, automação e funil — lacuna pequena.”	Privilegie semântica e evidência de projeto sobre matches literais.
Learning path curto	Sugerir trilhas de 7/14/30 dias só para as lacunas críticas.	“Para esta vaga, faltam SQL analítico e Looker Studio; plano de 10 horas.”	Foque só nas lacunas que mais aumentam a probabilidade de entrevista.
Carta de apresentação orientada à lacuna	Gerar uma carta que reconhece a lacuna e a compensa com evidência.	Texto curto, objetivo e alinhado ao anúncio.	Melhor curta e específica do que genérica e longa.
Recruiter outreach assistido	Gerar mensagem curta para recrutador/hiring manager.	Mensagem de 300–500 caracteres com prova de aderência.	Nunca peça “vaga”; peça “conversa sobre aderência”.
A/B testing de mensagem	Testar variações de assunto, CTA e framing.	Painel com taxa de resposta por template/segmento.	A/B por família de vaga, não por vaga individual.

Fluxo de UX recomendado

Etapas	Tela/ação	Decisão do sistema	Resultado
Descoberta	vaga entra no sistema	classifica por área, senioridade, local, modalidade	vai para fila do usuário
Triagem	usuário abre a vaga	score de aderência + explicação do score	cor verde/amarela/vermelha
Ponte de lacuna	score mede gaps	gera "faltam 2 itens críticos"	exibe plano rápido
Ajuste de currículo	usuário aceita recomendação	reordena experiências, destaca palavras-chave reais	currículo/versão da vaga é salvo
Mensagem	usuário escolhe canal	carta curta ou mensagem ao recrutador	histórico e experimento A/B
Candidatura	click-to-apply/prefill	sistema preenche o que puder	envio humano confirmado
Pós-candidatura	follow-up e entrevista	agenda lembrete e refina o modelo	feedback alimenta ranking futuro

Templates curtos de outreach

Template A — evidência direta

Olá, vi a vaga de **[cargo]** e achei a aderência alta porque já entreguei **[resultado/projeto]** usando **[habilidade-chave]**. Não cubro 100% dos requisitos, mas tenho base forte em **[área transferível]** e consigo chegar rápido no restante. Se fizer sentido, adoraria conversar brevemente sobre o fit.

Hipótese de uso: melhores resultados em vagas operacionais e generalistas.

Template B — lacuna explicitada com plano

Oi, me interessei pela vaga de **[cargo]**. Hoje eu cubro bem **[x]**, **[y]** e **[z]**, e minha principal lacuna é **[competência]**. Já comecei um plano objetivo para fechar isso nas próximas semanas. Mesmo assim, acredito que posso gerar valor imediato em **[frente principal]**.

Hipótese de uso: melhores resultados quando falta uma ferramenta, mas não a base da função.

Template C — portfólio/prova social

Olá! Me candidatei à vaga de **[cargo]**. Tenho experiência em **[problema semelhante]** e montei um portfólio/case curto mostrando como penso **[tema da vaga]**. Se ajudar, posso compartilhar. Achei a vaga especialmente interessante pelo foco em **[atributo da empresa/time]**.

Hipótese de uso: melhor para marketing, produto, design, dados e tech.

Regras de A/B test que valem a pena

Variável	Variante A	Variante B	Métrica
Assunto	"Aderência à vaga de [cargo]"	"[cargo] — experiência em [tema]"	taxa de abertura/resposta
Framing	ênfatisa resultado	ênfatisa motivação	taxa de resposta
CTA	"posso compartilhar um case?"	"faz sentido uma conversa breve?"	taxa de resposta positiva
Tamanho	280–350 caracteres	450–550 caracteres	resposta e conversão para entrevista

Funcionalidades de monitoramento e modelo de dados

Funcionalidades recomendadas

Funcionalidade	Regra recomendada
Consultas booleanas	suportar <code>AND</code> , <code>OR</code> , <code>NOT</code> , aspas e grupos, além de sinônimos por área. Ex.: <code>"engenheiro de dados" OR "data engineer" AND (python OR pyspark) NOT estagio</code> .
Geo e remoto	normalizar <code>cidade</code> , <code>UF</code> , <code>região</code> , <code>país</code> , <code>workplace_type</code> , <code>travel_required</code> .
Watchlist de empresas	seguir empresas e páginas; reforçar score quando a empresa entra em nova vaga compatível.
Faixa salarial	tratar salário como <code>min</code> , <code>max</code> , <code>currency</code> , <code>period</code> , <code>is_estimated</code> , <code>is_employer_provided</code> .
Senioridade	taxonomia única: <code>intern</code> , <code>junior</code> , <code>pleno</code> , <code>senior</code> , <code>staff/principal</code> , <code>manager</code> , <code>director</code> .
Canais de alerta	e-mail, push web/mobile, Telegram, WhatsApp Business, feed RSS próprio, webhook outbound.
Deduplicação	preservar cópias por fonte, mas criar um <code>canonical_job_id</code> .
Agendamento	polling por fonte, quiet hours, burst control, re Checagem de vagas críticas.
Application management	kanban: <code>nova</code> , <code>salva</code> , <code>aplicada</code> , <code>triagem</code> , <code>entrevista</code> , <code>teste</code> , <code>oferta</code> , <code>sem retorno</code> , <code>encerrada</code> .
Feedback loop	aprender com cliques, candidaturas, respostas, entrevistas e recusas.
Analytics	taxa de conversão por fonte, taxa de resposta por template, tempo até entrevista, fit score vs. resultado real.

Regras de deduplicação

Regra	Implementação sugerida
Chave forte	<code>source_job_id</code> quando existir e for confiável.
Chave canônica	hash de <code>company_normalized + title_normalized + city_normalized + workplace_type + seniority + salary_band</code> .
Similaridade fuzzy	títulos com similaridade alta após stemming e remoção de boilerplate; janela de publicação de 21 dias.
Prova de origem	manter <code>raw_payload</code> , <code>source_url</code> , <code>captured_at</code> , <code>source_name</code> .
Conflito de dados	priorizar campos pela ordem: API oficial > webhook > página oficial da vaga > e-mail > social post.
Fechamento	marcar como <code>stale</code> se a vaga sumir da fonte por N coletas consecutivas ou vier webhook/status de expiração.

SLA de freshness sugerido

Tipo de fonte	SLA alvo
Webhook oficial	até 5 min
API oficial com polling leve	5–15 min
Alertas por e-mail + parsing	5–20 min
Scraping seletivo de páginas públicas	15–60 min
Canais sociais públicos autorizados	5–30 min
Comunidades sem API oficial de leitura	horas ou humano no loop

Esquemas de dados de exemplo

Tabela `job_postings`

Campo	Tipo	Observação
<code>id</code>	UUID	PK interna
<code>canonical_job_id</code>	UUID	agrupa duplicatas
<code>source_name</code>	text	<code>linkedin</code> , <code>gupy</code> , <code>telegram</code> , etc.
<code>source_job_id</code>	text	ID externo
<code>source_url</code>	text	URL original
<code>title_raw</code>	text	título bruto
<code>title_normalized</code>	text	título normalizado

Campo	Tipo	Observação
<code>company_id</code>	UUID	FK
<code>location_raw</code>	text	local bruto
<code>city</code>	text	cidade normalizada
<code>state</code>	text	UF
<code>country</code>	text	país
<code>workplace_type</code>	enum	<code>onsite</code> , <code>hybrid</code> , <code>remote</code> , <code>unknown</code>
<code>seniority</code>	enum	taxonomia única
<code>employment_type</code>	enum	<code>clt</code> , <code>pj</code> , <code>intern</code> , <code>temp</code> , etc.
<code>salary_min</code>	numeric	mínimo
<code>salary_max</code>	numeric	máximo
<code>salary_currency</code>	text	<code>BRL</code> , <code>USD</code>
<code>salary_period</code>	enum	<code>hour</code> , <code>month</code> , <code>year</code>
<code>salary_confidence</code>	enum	<code>employer_provided</code> , <code>estimated</code> , <code>mentioned_text</code> , <code>none</code>
<code>requirements_text</code>	text	requisitos
<code>benefits_text</code>	text	benefícios
<code>application_type</code>	enum	<code>apply_on_platform</code> , <code>apply_on_company_site</code> , <code>external_form</code> , <code>email</code> , <code>social_dm</code>
<code>posting_date</code>	timestampz	data original
<code>captured_at</code>	timestampz	quando entrou no seu sistema
<code>status</code>	enum	<code>active</code> , <code>stale</code> , <code>closed</code> , <code>unknown</code>
<code>raw_payload</code>	jsonb	evidência da coleta

Índices: `canonical_job_id`, `source_name + source_job_id`, `posting_date`, `title_normalized`, `company_id`, `city + state`, `workplace_type`, `GIN(raw_payload)`.

Tabela `companies`

Campo	Tipo	Observação
<code>id</code>	UUID	PK
<code>name_raw</code>	text	nome original
<code>name_normalized</code>	text	nome limpo
<code>domain</code>	text	domínio principal

Campo	Tipo	Observação
<code>linkedin_url</code>	text	opcional
<code>gupy_career_page</code>	text	opcional
<code>glassdoor_url</code>	text	opcional
<code>industry</code>	text	setor
<code>size_band</code>	text	faixa de porte
<code>headquarters_city</code>	text	opcional
<code>country</code>	text	país
<code>watchlist_score</code>	numeric	afinidade com usuário

Tabela `users`

Campo	Tipo	Observação
<code>id</code>	UUID	PK
<code>email</code>	citext	login
<code>name</code>	text	nome
<code>timezone</code>	text	ex.: <code>America/Sao_Paulo</code>
<code>resume_master_url</code>	text	CV principal
<code>profile_json</code>	jsonb	skills, senioridade, salários, preferências
<code>privacy_settings</code>	jsonb	consentimentos e canais
<code>quiet_hours_json</code>	jsonb	janelas sem alertas
<code>visibility_prefs</code>	jsonb	empresas ocultas, perfis visíveis, etc.
<code>created_at</code>	timestampz	auditoria

Tabela `applications`

Campo	Tipo	Observação
<code>id</code>	UUID	PK
<code>user_id</code>	UUID	FK
<code>job_posting_id</code>	UUID	FK
<code>resume_version_id</code>	UUID	versão usada
<code>cover_letter_version_id</code>	UUID	opcional
<code>status</code>	enum	pipeline da candidatura
<code>status_reason</code>	text	rejeição, ghosting etc.

Campo	Tipo	Observação
<code>applied_at</code>	timestampz	data de candidatura
<code>next_action_at</code>	timestampz	follow-up
<code>interview_at</code>	timestampz	entrevista
<code>recruiter_contact</code>	jsonb	nome/canal
<code>notes</code>	text	observações
<code>feedback_json</code>	jsonb	resposta real do mercado
<code>source_submission_evidence</code>	jsonb	screenshot/url/id externo

Tabela `alerts`

Campo	Tipo	Observação
<code>id</code>	UUID	PK
<code>user_id</code>	UUID	FK
<code>name</code>	text	nome do alerta
<code>query_boolean</code>	text	expressão
<code>filters_json</code>	jsonb	geo, remoto, salário, empresa
<code>channels_json</code>	jsonb	email, telegram, whatsapp, rss
<code>schedule_json</code>	jsonb	frequência
<code>freshness_target_minutes</code>	integer	SLA por alerta
<code>is_active</code>	boolean	status

Tabela `event_logs`

Campo	Tipo	Observação
<code>id</code>	bigserial	PK
<code>event_type</code>	text	<code>ingest_ok</code> , <code>dedupe_merge</code> , <code>alert_sent</code> , <code>apply_confirmed</code>
<code>entity_type</code>	text	<code>job</code> , <code>application</code> , <code>user</code>
<code>entity_id</code>	UUID	entidade
<code>source_name</code>	text	origem
<code>severity</code>	text	info/warn/error
<code>payload</code>	jsonb	detalhes
<code>created_at</code>	timestampz	auditoria

Campo	Tipo	Observação
<code>trace_id</code>	text	rastreabilidade

Como o sistema lida com currículo, histórico profissional, pretensão salarial, mensagens e possivelmente dados ligados à inclusão, convém separar **campos de perfil, campos sensíveis opcionais e evidências de candidatura** em domínios distintos, com masking, criptografia em repouso, retenção temporal e controles de acesso por papel. Isso reduz risco de LGPD e facilita atender solicitações de exclusão/exportação. ⁴²

Roadmap, stack recomendada, custos e limitações

Roadmap priorizado

Fase	Objetivo	Entregas	Esforço estimado
MVP	ter um agregador útil e juridicamente conservador	ingestão de alertas por e-mail; conectores oficiais quando houver; captura pública em Empregos/Trampos/Gupy portal; normalização; dedupe; ranking básico; painel de candidaturas; alertas por e-mail/Telegram; RSS próprio	4-6 semanas
v1	virar cockpit de candidatura	múltiplas versões de currículo/carta; scoring explicável; watchlists; agenda de entrevistas; follow-up; analytics básicos; conectores Gupy/Vagas/Catho/Indeed em contas autorizadas	6-10 semanas
v2	fechar o ciclo de aprendizagem	extensão de navegador; assistente de prefill; learning paths; A/B testing de outreach; BI avançado por fonte; SLA/frescor por origem; regras de retenção e DSRs completas	10-16 semanas

Stack recomendada por camada

Camada	Open source / libs	Serviço comercial opcional	Custo relativo
Ingestão e automação	n8n , Python, FastAPI, Playwright	Workato / Zapier / Make	baixo → alto
Banco transacional	PostgreSQL	Neon, Supabase, RDS equivalente	baixo → médio
Busca / ranking	pgvector , Meilisearch, OpenSearch	Elastic Cloud	baixo → alto
Filas / jobs	Redis , Celery, RQ	SQS/Cloud Tasks	baixo → médio
Armazenamento de anexos	MinIO	S3/Blob Storage	baixo → médio

Camada	Open source / libs	Serviço comercial opcional	Custo relativo
Front-end	Next.js , React	Vercel/Netlify	baixo → médio
Auth	Keycloak	Auth0 / Clerk	baixo → alto
BI	Metabase , Superset	Power BI / Looker	baixo → alto
Observabilidade	OpenTelemetry , Grafana, Loki	Datadog / New Relic	baixo → alto
Agenda	Cal.com	Google Workspace / Microsoft 365	baixo → médio
Alertas e e-mail	SMTP próprio, Resend/Postmark	Customer.io / Braze	baixo → alto
Telegram	Telegram Bot API	—	baixo
WhatsApp	WhatsApp Cloud API	Twilio / 360dialog	médio → alto

Custos relativos por arquitetura

Arquitetura	Infra	Operação	Jurídico/compliance	Custo total relativo
A — alertas + inbox	baixo	baixo	baixo	baixo
B — híbrida com scraping seletivo	médio	médio/alto	médio	médio
C — assistente de navegador	médio	alto	médio/alto	médio/alto
D — hub enterprise	alto	alto	alto	alto

Recomendação objetiva de implementação

Se o objetivo for **máximo valor com menor risco**, eu faria assim:

1. **Comece por fontes com alto valor e baixo atrito jurídico:** Gupy público + alertas de LinkedIn/Indeed/Catho/Vagas/InfoJobs + Empregos.com.br + Trampos.co.
2. **Use Telegram, e-mail e RSS próprio como saídas prioritárias;** deixe WhatsApp como canal premium opcional de saída, não como origem de dados de terceiros.
3. **Imponha humano no loop para aplicar;** o sistema pode ranquear, preparar, preencher e lembrar, mas não deve “atirar currículo” silenciosamente em massa.
4. **Só habilite APIs corporativas** de Gupy, Vagas, Catho, PandaPé/InfoJobs e Indeed quando houver credenciais/parceria/autorização direta.
5. **Trate Glassdoor como contexto**, não como backbone, porque hoje ele já depende do Indeed para candidatura e não apoia novas parcerias de API. ⁴³

Questões em aberto e limitações

Há três limitações importantes nesta pesquisa. A primeira é que **algumas páginas do domínio principal da Vagas.com não ficaram acessíveis ao crawler**, embora a ajuda e a documentação para empresas tenham ficado; por isso, a leitura de restrições lado candidato em Vagas foi feita de forma conservadora. A segunda é que **muitas plataformas não publicam publicamente rate limits detalhados nem feeds RSS para candidatos**; quando eu marquei “não localizado”, foi ausência de documentação oficial encontrada, não prova absoluta de inexistência. A terceira é que **várias integrações oficiais são claramente B2B/partner-only** — sobretudo em Indeed, Gupy, Vagas Empresas, Catho API Pública e PandaPé — o que muda o desenho dependendo de você ser um produto para candidatos, uma consultoria, uma universidade ou uma empresa parceira. ⁴⁴

¹ ¹² ²⁷ ³⁴ ³⁵ ⁴⁰ ⁴³ <https://developers.gupy.io/>
<https://developers.gupy.io/>

² ⁵ ³⁷ <https://www.linkedin.com/legal/crawling-terms>
<https://www.linkedin.com/legal/crawling-terms>

³ ⁴⁴ <https://forbusiness.vagas.com.br/developers>
<https://forbusiness.vagas.com.br/developers>

⁴ ³⁶ ⁴² [L13709 - Planalto](https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm?utm_source=chatgpt.com)
https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm?utm_source=chatgpt.com

⁶ ²⁰ <https://www.linkedin.com/help/linkedin/answer/a511279/alertas-de-vaga-no-linkedin?lang=pt>
<https://www.linkedin.com/help/linkedin/answer/a511279/alertas-de-vaga-no-linkedin?lang=pt>

⁷ ²² <https://ajuda.vagas.com.br/portal/pt-br/kb/articles/alerta-aplicativo>
<https://ajuda.vagas.com.br/portal/pt-br/kb/articles/alerta-aplicativo>

⁸ ²³ ⁴¹ https://www.infojobs.com.br/ajuda/como_usar_infojobs_area_de_candidato__1292.aspx
https://www.infojobs.com.br/ajuda/como_usar_infojobs_area_de_candidato__1292.aspx

⁹ ²⁴ [Vagas de emprego em todo Brasil](https://www.catho.com.br/vagas/?utm_source=chatgpt.com)
https://www.catho.com.br/vagas/?utm_source=chatgpt.com

¹⁰ ²⁵ ³⁸ <https://br.indeed.com/legal>
<https://br.indeed.com/legal>

¹¹ <https://www.glassdoor.com.br/sobre/terms/>
<https://www.glassdoor.com.br/sobre/terms/>

¹³ <https://www.empregos.com.br/>
<https://www.empregos.com.br/>

¹⁴ <https://tramos.co/oportunidades>
<https://tramos.co/oportunidades>

¹⁵ ²⁹ <https://www.geekhunter.com.br/vagas>
<https://www.geekhunter.com.br/vagas>

¹⁶ ³⁰ <https://www.revelo.com.br/revelo.com.br>
<https://www.revelo.com.br/revelo.com.br>

¹⁷ ³¹ <https://core.telegram.org/bots/api>
<https://core.telegram.org/bots/api>

- 18 <https://developers.facebook.com/documentation/business-messaging/whatsapp/get-started>
<https://developers.facebook.com/documentation/business-messaging/whatsapp/get-started>
- 19 33 https://developers.facebook.com/docs/pages-api/overview?locale=pt_BR
https://developers.facebook.com/docs/pages-api/overview?locale=pt_BR
- 21 <https://br.linkedin.com/jobs/view/project-and-operations-specialist-%2480-hr-remote-at-crossing-hurdles-4405758613>
<https://br.linkedin.com/jobs/view/project-and-operations-specialist-%2480-hr-remote-at-crossing-hurdles-4405758613>
- 26 https://www.glassdoor.com.br/Vaga/bras%C3%ADlia-vagas-SRCH_IL.0%2C8_IC2494161.htm
https://www.glassdoor.com.br/Vaga/bras%C3%ADlia-vagas-SRCH_IL.0%2C8_IC2494161.htm
- 28 <https://tramos.co/oportunidades/772853-analista-de-bi>
<https://tramos.co/oportunidades/772853-analista-de-bi>
- 32 <https://developers.facebook.com/documentation/business-messaging/whatsapp/about-the-platform>
<https://developers.facebook.com/documentation/business-messaging/whatsapp/about-the-platform>
- 39 <https://www.gupy.io/aviso-de-privacidade-candidatos>
<https://www.gupy.io/aviso-de-privacidade-candidatos>